



北京大学
PEKING UNIVERSITY

世界模型 World Model

四大主流范式与 LeWorldModel 创新



汇报人：郭湘琦



日期：2026/05/26






目录

CONTENTS

- | | | | |
|----|----------------|----|---------------------|
| 01 | 为什么需要世界模型？ | 02 | 范式一：推理范式（潜空间） |
| 03 | 范式二：生成范式（像素空间） | 04 | 范式三：结构范式（几何空间） |
| 05 | 范式四：仿真范式（物理空间） | 06 | 范式对比与LeWorldModel创新 |

引言：什么是世界模型？

给定过去和现在的观测，构建一个对环境的内部理解（外部世界的隐式表征），然后预测未来会怎么变



引言：为什么需要世界模型？

LeCun 的「蛋糕论」(NIPS 2016)

强化学习 (RL) 只是蛋糕上的樱桃

监督学习 是外面的糖霜

自监督学习 才是蛋糕本体

核心洞察：

人类每天处理数十万帧视觉输入，
却很少收到显式标签——婴儿不需要人告诉它「这是重力」


世界模型的核心价值

LLM 的局限：

- 擅长语言推理，但缺乏物理世界因果机制理解
- 无法真正预测“如果我这样做，世界会怎样变化”

应用场景：

- | | |
|---------|---------|
| • 机器人操控 | • 自动驾驶 |
| • 强化学习 | • 视频生成 |
| • 物理推理 | • 自主智能体 |



范式一：推理范式（潜空间）

World Models 奠基之作

核心架构（三部分）

- ① **VAE**: 压缩观测到潜空间
- ② **MDN-RNN**: 预测未来潜状态 $h_{t+1} = RNN(h_t, a_t)$
- ③ **Controller**: 在「想象」中训练的策略 $a_t = \pi(h_t)$

✓ 历史意义

证明完全在潜空间「想象」中训练的策略可以迁移到真实环境
奠定了「世界模型 = 潜空间动力学模型」的基础范式

✗ 局限性

VAE 像素重建成本高，潜空间不够结构化
MDN-RNN训练不稳定，难以扩展到复杂任务

范式一：推理范式（二）

RSSM架构 (Recurrent State Space Model)

RSSM核心创新：

将潜在状态分解为随机分量（捕捉环境不确定性）与确定性分量（捕捉上下文），通过「latent imagination」进行长期策略优化。

- 确定性路径： $h_t = f(h_{t-1}, a_{t-1}) \rightarrow$ 捕捉可预测的动态
- 随机路径： $s_t \sim p(s_t | h_t, o_t) \rightarrow$ 建模不确定性
- 联合推理：既能预测，又能处理部分可观测性

✓ 历史意义

DreamerV3 无需人类数据在单人 Minecraft 中达成钻石成就
证明了 RSSM 在连续控制任务中的强大性能

✗ 局限性

仍然依赖重构损失，潜空间不够结构化
计算成本随状态维度增长而急剧增加

范式一：推理范式（三）

🔄 范式转变：非生成式世界模型

JEPA (Joint-Embedding Predictive Architecture)

核心思想：联合嵌入预测架构

- 不预测像素，而是预测潜空间的表示
- Encoder: $x_t \rightarrow h_t$ (感知模块)
- Predictor: $(h_t, a_t) \rightarrow h_{t+1}$ (认知模块)
- 目标：最小化潜空间距离，而非像素级重建

✓ 历史意义

LeCun 的自主机器学习（AMI）愿景的核心组件
避免了生成式模型的「像素级细节陷阱」

✗ 局限性

表示崩溃（representation collapse）：潜空间退化到单点
方差正则化（Variance Regularization）效果有限




- 核心思想：在潜空间中进行状态推理

输入： (h_t, a_t) → 输出： h_{t+1}

- 其中 $h_t \in \mathbb{R}^d$ 是低维潜变量

技术流程：

- 1. 编码： $h_t = E(x_t)$ （观测 → 潜空间）
- 2. 预测： $h_{t+1} = f_\theta(h_t, a_t)$ （状态转换）
- 3. 重构： $\hat{x}_{t+1} = D(h_{t+1})$ （潜空间 → 观测）



范式二：生成范式（一）

🎬 Sora：文本/图像 → 视频生成

技术特点：

- 基于Diffusion Transformer（DiT）架构
- 时空潜在空间（spatio-temporal latent space）
- 可以生成60秒的高质量视频
- 视频中的物理规律「看起来」很真实

✓ 历史意义

掀起了视频生成革命，证明了大模型在视频生成中的潜力
让业界重新思考：视频生成模型是否是世界模型？

✗ 局限性

物理规律不完全准确（例如：杯子里的水不会真实流动）
计算成本极高，难以用于实时决策
缺乏因果推理能力（「如果...会怎样」的推理）

范式二：生成范式（二）

🎮 Genie: 从视频中学习可玩游戏世界

技术特点:

- 无需动作标签，自监督学习
- 三阶段：视频 → VQ-VAE → Transformer → 可玩游戏
- 可以生成多种游戏风格（平台跳跃、解谜等）

✓ 历史意义

证明了无需动作标签，也能学习可玩的世界模型
为游戏生成和 procedural content generation 提供新思路

✗ 局限性

生成的游戏世界比较简单，难以扩展到复杂物理交互
缺乏长期一致性（long-term consistency）

生成范式：像素空间直接预测


- 核心思想：在像素空间中直接生成未来观测

输入： x_t $\rightarrow$ 输出： x_{t+1}

- 其中 $x_t \in \mathbb{R}^{H \times W \times 3}$ 是原始像素空间观测

技术特点：

- 无需显式潜空间编码，直接端到端生成
- 基于扩散模型（Diffusion）或自回归（AR）架构
- 生成质量高，但计算成本高，难以用于实时决策



范式三：几何范式（一）

OccWorld: 3D占用空间中的世界模型

核心创新：3D占用表示

- 为什么用3D占用？表达能力强 + 获取效率高 + 适配性好
- Scene Tokenizer: 将3D占用离散化为token
- 时空生成Transformer: 同时预测场景演化和ego轨迹

✓ 历史意义

在3D占用空间中构建世界模型的工作
为端到端自动驾驶提供了可解释的基线

✗ 局限性

3D占用分辨率有限，难以建模细粒度几何
长期预测的一致性挑战

范式三：几何范式（二）

从 BEVFormer 到 BEVWorld: BEV空间中的世界模型

BEVFormer: BEV统一表示的基础

- Spatial Cross-Attention: 将多视角图像特征转换到BEV空间
- Temporal Self-Attention: 融合历史BEV特征，建模时序动态

BEVWorld: BEV表示走向世界模型

- 将多模态输入编码为紧凑BEV latent
- 用BEV序列扩散模型预测未来场景
- 可引入高层动作token，模拟不同未来

✓ 历史意义

BEVFormer证明了BEV统一空间对自动驾驶感知的价值
BEVWorld进一步把BEV空间用于未来预测与世界模拟

✗ 局限性

BEV仍是对3D世界的压缩，可能丢失高度和细粒度几何


- 核心思想：在几何空间中建模环境结构

输入： (G_t, a_t) → 输出： G_{t+1}

- 其中 $G_t \in \mathbb{R}^{N \times 3}$ 或 BEV 表示（点云/鸟瞰图）

技术特点：

- 显式建模3D几何结构（深度、occupancy、点云）
- 适合自动驾驶、机器人等需要空间理解的任务
- 平衡了表达能力和计算效率



范式四：仿真范式

Genesis：生成式物理引擎

核心创新：物理引擎 + 生成式AI

- 底层：通用物理引擎（支持刚体、软体、混合体）
- 上层：VLM驱动的世界模型，自动生成4D物理世界
- 性能：仿真速度可达4300万FPS（实时速度的43万倍）

✓ 历史意义

将生成式AI与物理引擎深度结合的开源平台
为机器人Sim2Real提供了高质量数据生成工具

✗ 局限性

物理精度受限于求解器精度
生成内容与真实世界的gap仍然存在


- 核心思想：在物理空间中模拟真实物理规律

输入： $(P_t, a_t, physics_rules) \rightarrow$ 输出： P_{t+1}

- 其中 P_t 包含位置、速度、质量等物理属性

技术特点：

- 集成物理引擎（刚体动力学、流体仿真、软体仿真）
- 严格遵循物理定律（牛顿力学、能量守恒等）
- 可解释性强，但计算成本高，难以端到端学习



💎核心洞察：四种范式 = 同一个公式的不同实例化

$$f_{\theta}: (o_t, a_t) \rightarrow o_{t+1}$$

s

四种范式的区别：观测空间 o 的表示不同！

范式	建模空间	输入	输出
• 推理范式	潜空间	(h_t, a_t)	h_{t+1}
• 生成范式	像素空间	x_t	x_{t+1}
• 结构范式	几何空间	(G_t, a_t)	G_{t+1}
• 仿真范式	物理空间	(P_t, a_t)	P_{t+1}

LeWorldModel: 问题背景

🔔 JEPA的核心问题：表示崩溃 (Representation Collapse)

什么是表示崩溃？

- 潜空间中所有观测都被映射到相同的表示 (mode collapse)
- 模型无法区分不同状态，预测失去意义
- 示例：在DMControl的Cheetah任务中，所有状态都被编码为 $[0.1, 0.2, \dots, 0.1]$

✗ 现有方法的局限

- 依赖复杂多术语损失 (如PLDM需要6个超参数)
- 使用指数移动平均 (EMA)、停止梯度 (SG) 等启发式技巧
- 需要预训练编码器或辅助监督来避免表示崩溃
- 训练不稳定，难以扩展到复杂任务

LeWorldModel: SIGReg方法

🎯核心思想：强制潜变量分布接近标准高斯分布

$$\mathcal{L}_{LeWM} = \underbrace{\frac{1}{BT} \sum_{i=1}^B \sum_{t=1}^T \| \widehat{z}_{t+1}^{(i)} - z_{t+1}^{(i)} \|_2^2}_{\mathcal{L}_{pred}} + \lambda \cdot \underbrace{\frac{1}{M} \sum_{m=1}^M T! (\mathbf{h}^{(m)})}_{\text{SIGReg}}$$


公式解释

- B : batch size, T : 轨迹长度
- $\hat{z}_{t+1} = pred_{\phi}(z_t, a_t)$ (预测器)
- $z_{t+1} = enc_{\theta}(o_{t+1})$ (编码器)
- M=1024 : 随机投影方向数
- λ : 唯一需要调优的超参数 (默认 0.1)

✓ 技术优势

- 理论保证：标准高斯分布具有最大熵，防止表示退化
- 简单高效：只需在损失函数中加入正则项
- 通用性强：可应用于任何JEPA架构

LeWorldModel: 模型架构



编码器（Encoder）： Vision Transformer Tiny

- patch_size=14, 12层, 3头注意力, 隐维度192
- 输入224×224 RGB图像, 输出192维潜表示
- 从[CLS] token提取, 经1层MLP+BatchNorm投影

预测器（Predictor）： Transformer

- 6层, 16头注意力, dropout=10%
- 动作通过AdaLN（Adaptive Layer Normalization）注入每层WW
- AdaLN参数初始化为零, 确保动作条件渐进生效

总参数量: 约15M, 单GPU数小时可完成训练

训练数据: 仅需要未标注的观测-动作轨迹 (无奖励信号)

LeWorldModel: 潜空间规划

测试阶段采用模型预测控制（MPC）框架，在潜空间中进行动作优化

Step 1 — 编码初始与目标观测：

- $z_1 = \text{Encoder}(o_1)$, $z_g = \text{Encoder}(o_g)$

Step 2 — 交叉熵方法（CEM）优化动作序列：

- 每步采样300个候选动作序列 → 预测器展开潜轨迹
- 计算目标匹配代价 $C = ||\hat{z}_H - z_g||^2$
- 选取代价最低的30个精英序列更新分布
- 重复30轮直至收敛

Step 3 — MPC滚动时域：执行首个动作，重新观测并重新规划

- 规划时域 $H=5$ （对应25个环境步，frame skip=5）



LeWorldModel: 实验设置

实验设置:


实验环境:

- PushT: 2D操纵, 将T形块推至目标位置
- TwoRoom: 2D双房间导航任务
- Reacher: 2D双关节机械臂 reaching
- OGBench-Cube: 视觉丰富的3D操纵

对比方法:

- DINO-WM: 冻结DINOv2编码器 (ICML 2025)
- PLDM: 端到端JEPA, 7项VICReg损失需调6个超参数, 训练极不稳定
- GCBC: 目标条件行为克隆
- GCIVL / GCIQL: 目标条件离线强化学习

LeWorldModel: 实验结果——性能对比



✓ 关键结果


PushT任务：LeWM成功率87%，超过DINO-WM（74%）和PLDM（69%）

OGBench-Cube：DINO-WM略优（74% vs 48%），3D环境视觉复杂度对编码器训练挑战更大

TwoRoom：PLDM和DINO-WM反而优于LeWM——简单环境内在维度低，SIGReg强制高维高斯可能过度正则化


规划速度：LeWM 0.98秒 vs DINO-WM 47秒，快约48倍（潜维度192 vs 数千维，token数少200倍）

LeWorldModel: 实验结果——训练稳定性与超参数



LeWorldModel (2项损失)

- 预测损失 L_{pred} : 平滑单调下降
- SIGReg: 早期快速下降后趋于平稳
- 仅需调节1个超参数 λ
- λ 可用二分搜索优化, $O(\log n)$ 复杂度
- ViT/ResNet-18两种编码器均表现良好
- 表示维度超过阈值后性能迅速饱和



PLDM (7项损失)

- 预测损失 + 方差/协方差损失
- 时间相似性/方差/协方差损失
- 逆动力学模型损失
- 损失曲线嘈杂、非单调
- 需调6个超参数 ($\alpha, \beta, \gamma, \zeta, \nu, \mu$)
- 网格搜索复杂度 $O(n^6)$

LeWorldModel: 物理理解评估

实验1 — 物理量探针 (Physical Probing) :

- 从潜表示中用线性探针/MLP预测物理量 (agent位置、block位置、角度)
- LeWM consistently 优于PLDM, 与DINO-WM相当
- 仅用端到端学习即接近DINOv2预训练特征 (DINOv2在约1.42亿张图像上预训练)

实验2 — 潜空间可视化 (t-SNE) :

- 潜空间保留了环境的空间结构: 相邻物理状态在潜空间中也相邻
- 表明LeWM学到了有意义的结构化表示

实验3 — 违反期望测试 (VoE, 灵感来自发展心理学) :

- 视觉扰动 (物体变色) vs 物理扰动 (物体瞬间传送)
- LeWM对物理扰动表现出显著更高的'惊讶' (预测误差) , $p < 0.01$
- 能够区分'违反物理'与'视觉变化'

LeWorldModel: 局限性与未来方向

局限1 — 规划时域受限:

- 当前潜在世界模型仍局限于短 horizon (如5步), 层级化世界模型是重要方向

局限2 — 数据覆盖要求:

- 依赖具有充分交互覆盖的离线数据集
- 在内在维度极低的简单环境 (如Two-Room) 中, 强制高斯先验可能反而有害

局限3 — 动作标注依赖:

- 目前需要显式动作标注。未来可通过逆动力学建模学习动作表示, 减少标注需求

局限4 — 3D环境挑战:

- 在OGBench-Cube等复杂3D环境中, 端到端训练编码器仍具挑战, 预训练视觉先验可能仍有优势



1. Ha D, Schmidhuber J. World models[J]. arXiv preprint arXiv:1803.10122, 2018, 2(3): 440.
2. Hafner D, Pasukonis J, Ba J, et al. Mastering diverse control tasks through world models[J]. Nature, 2025, 640(8059): 647-653.
3. Assran M, Duval Q, Misra I, et al. Self-supervised learning from images with a joint-embedding predictive architecture[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2023: 15619-15629.
4. Brooks, T., Peebles, B., Holmes, C., DePue, W., Guo, Y., Jing, L., Schnurr, D., Taylor, J., Luhman, T., Luhman, E., Ng, C., Wang, R., & Ramesh, A. (2024). Video generation models as world simulators. OpenAI. <https://openai.com/index/sora/>.
5. Bruce J, Dennis M D, Edwards A, et al. Genie: Generative interactive environments[C]//Forty-first International Conference on Machine Learning. 2024.
6. Zheng W, Chen W, Huang Y, et al. Occworld: Learning a 3d occupancy world model for autonomous driving[C]//European conference on computer vision. Cham: Springer Nature Switzerland, 2024: 55-72.

- 
8. Li Z, Wang W, Li H, et al. Bevformer: learning bird's-eye-view representation from lidar-camera via spatiotemporal transformers[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2024, 47(3): 2020-2036.
 9. Zhang Y, Gong S, Xiong K, et al. Bevworld: A multimodal world model for autonomous driving via unified bev latent space[J]. 2024.
 10. Genesis Embodied AI. (2024). Genesis: A generative physics engine for general-purpose robotics [Computer software]. GitHub. <https://github.com/Genesis-Embodied-AI/Genesis>
 11. Ding J, Zhang Y, Shang Y, et al. Understanding world or predicting future? a comprehensive survey of world models[J]. ACM Computing Surveys, 2025, 58(3): 1-38.
 12. Maes L, Lidec Q L, Scieur D, et al. Leworldmodel: Stable end-to-end joint-embedding predictive architecture from pixels[J]. arXiv preprint arXiv:2603.19312, 2026.



感谢各位老师同学批评与指导



汇报人：郭湘琦



日期：2026/05/26