

FMVP: Masked Flow Matching for Adversarial Video Purification

基于掩码流匹配的对抗视频净化

[arxiv, 2026.01.05](#)

研究背景 — 视频对抗攻击

视频对抗攻击通过在输入数据中添加人类肉眼无法察觉的微小扰动来诱导深度神经网络模型做出错误的分类；其在视频内容审查，人脸识别系统等领域构成安全威胁。

视频攻击分类（部分）：

- 基于对抗性梯度：如Projected Gradient Descent（PGD），一种迭代攻击

$$g = \nabla_x \mathcal{L}(f_\theta(x), y_{true}) \quad \|\delta\|_\infty = \max(|x'_i - x_i|) \leq \epsilon$$

- 基于优化：如CW攻击，通过最小化 $\|\delta\|_2 + c \cdot f(x + \delta)$ 找到一个既隐蔽又有效的扰动

$$\|\delta\|_2 = \sqrt{\sum_i (x'_i - x_i)^2} \leq \epsilon$$

- 自适应攻击方法：如DiffHammer（DH），通过多步评估进行选择性的梯度攻击，主要针对对抗净化

研究背景 — 防御手段

对抗训练

直接用对抗样本训练分类网络，提高该模型在面对攻击时的鲁棒性；

缺点：泛化能力差，算力开销大，对干净数据的识别准确率可能降低



对抗净化

将受到攻击的视频数据通过一个净化网络还原为未被污染的数据，再喂给分类网络



a. Defense Pattern(DP) /

Temporal Shuffling(TS)

DP主动在输入视频上全部叠加一层干扰图案，TS则打乱输入的帧顺序；二者都属于梯度掩蔽的防御方法，对基于梯度的攻击很有效，但没有真正还原数据，不能恢复原视频中的语义信息。




b. DiffPure

先在输入视频上叠加一层干扰图案，再基于扩散模型训练一个神经网络来逆转这个过程，并在其中消除对抗攻击所叠加的干扰。



c. FlowPure

通过流匹配直接将对抗样本还原为干净的视频。



研究背景 — 防御手段的主要缺陷

1. 基于扩散模型的方法（如 DiffPure）的缺陷：

-采样效率低：生成过程需要多步迭代，速度较慢。


-轨迹问题：依赖随机过程，导致生成轨迹是弯曲且随机的；这增加了从噪声恢复到干净数据的难度和不确定性。

2. 基于流匹配的方法（如 FlowPure）的缺陷：

-惰性学习（Lazy learning）：由于对抗样本和干净样本在空间上距离非常近（扰动很小），在没有额外机制来主动破坏对抗结构的情况下直接训练模型从对抗视频映射到干净视频可能会导致模型保留对抗攻击的掩码细节，导致最终的净化效果不理想。

3.对频域特征的忽视：

-忽视频谱分布：现有的净化方法主要关注空间重构约束，即像素层面的恢复而忽略了频率的线索：对抗扰动通常表现为高频异常（异常的噪点、边缘锐化），而语义内容主要是低频的。现有方法忽略了这一关键的频谱分布差异，未能利用频域信息来辅助去除噪声。



“Therefore, additional mechanisms are needed to actively disrupt adversarial structures and guide the model toward clean reconstruction.”

主要方法 — 扩散模型和流匹配技术

1. 扩散模型 (Diffusion models)

以Denoising Diffusion Probabilistic Models (DDPMs) 为例，此技术包含两个过程

- 前向过程：逐渐向视频添加高斯噪声，直到数据变成完全的随机噪声。

$$q(\mathbf{x}_t|\mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \sqrt{\bar{\alpha}_t}\mathbf{x}_0, (1 - \bar{\alpha}_t)\mathbf{I})$$

- 反向过程：训练一个神经网络来逆转这个过程，从噪声中一步步去噪恢复出真实数据。

$$\mathcal{L}_{\text{DDPM}} = \mathbb{E}_{t, \mathbf{x}_0, \epsilon} [\|\epsilon - \epsilon_{\theta}(\sqrt{\bar{\alpha}_t}\mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t}\epsilon, t)\|^2]$$

扩散模型依赖随机过程链 (stochastic chains or SDEs)

主要方法 — 扩散模型和流匹配技术

2. 流匹配 (Flow Matching)

训练连续归一化流 (CNF)，方法是由

$$\frac{d\mathbf{x}}{dt} = v_t(\mathbf{x}), \quad \text{s.t.} \quad \mathbf{x}_0 \sim p_0, \mathbf{x}_1 \sim p_{data}.$$

和

$$\frac{\partial p_t(x)}{\partial t} + \nabla \cdot (p_t(x)v_t(x)) = 0$$

得到概率密度分布 p 和速度矢量，再通过

$$\mathcal{L}_{\text{CFM}}(\theta) = \mathbb{E}_{t,q(\mathbf{z}),p_t(\mathbf{x}|\mathbf{z})} [\|v_\theta(\mathbf{x}, t) - u_t(\mathbf{x}|\mathbf{z})\|^2]$$

计算得到 v_θ ，再逐步迭代得到 $\mathbf{x}_1$ ；整个过程都是解ODE

FMVP模型 (1)

— 基本设定

令 f_ϕ 表示一个由 ϕ 参数化的预训练视频分类器, (x^{clean}, y) 表示一个干净的视频样本及其对应的真实标签。对抗攻击算法 $\mathcal{A}$ 通过添加不可感知的扰动生成对抗视频 $x^{adv} = \mathcal{A}(x^{clean}, y, f_\phi)$, 使得分类器被误导从而做出错误的预测, 即 $f_\phi(x^{adv}) \neq y$ 。基于生成的对抗净化旨在学习一个生成器 G_θ , 将对抗视频 x^{adv} 映射回干净数据流形。其目标是在移除对抗扰动的同时保留语义内容, 确保净化后的视频能被目标模型正确分类: $f_\phi(\tilde{G}_\theta(x^{adv})) = y$ 。

扩散模型的前向过程 + 流匹配 + 复原时频率门控约束

FMVP模型（2） — 扩散模型的前向过程

令 $\mathbf{x}^{adv} \in \mathbb{R}^{B \times C \times T \times H \times W}$ 表示一个受对抗扰动的视频输入。如图所示，PGD或CW攻击产生的对抗扰动在像素空间中通常是微小且不可感知的，这凸显了外加一个可控噪声来破坏这种对抗模式的必要性，若直接使用流匹配的话恢复效果不好。




Figure 3: The trajectories of 50 real samples in the space from clean $\rightarrow$ adversarial $\rightarrow$ masked $\rightarrow$ purified. Left: CW attack; right: PGD attack.

FMVP模型（2） — 扩散模型的前向过程

具体方法：

先决定一个保留比例 ρ （0.2~0.6），如果该位置的均匀随机值小于 ρ ，则设置 $m = 1$ ，否则为0；

然后用以下公式叠加噪声：

$$x_0 = m \odot (x_{adv} + \xi \epsilon) + (1 - m) \odot \epsilon, \quad \epsilon \sim \mathcal{N}(0, I)$$

其中 ξ 是一个可忽略的噪声因子（例如 10^{-5} ），引入它是为了阻止保留区域的分布退化，以此确保数值稳定性，完成扩散模型中叠加噪声的部分。

FMVP模型（3） — 流匹配

使用最简单高效的流匹配模式，Optimal Transport（OT）分布路径：

$$x_t = (1 - t)x_0 + tx_1, \quad t \sim \mathcal{U}(0, 1) \quad x_1 := x^{clean}$$

那么真实速度场就是恒定的：

$$u^* = \frac{dx_t}{dt} = x_1 - x_0$$

因此可以使用3D U-Net训练流匹配网络模型 v_θ ：

$$\mathcal{L}_{CFM}(\theta) = \mathbb{E}_{t, x_0, x_1} [\|v_\theta(x_t, t) - (x_1 - x_0)\|_2^2]$$

FMVP模型（4）

— 频率门控约束（Frequency-Gated Constrain）

为了进一步规范学习过程，使其做出能在图像含义方面有意义的重建，该模型通过引入频域约束显式抑制了高频分量（对抗噪声集中于此）。

令 $\mathcal{F}(\cdot)$ 表示对每个通道、时间帧和批次元素独立应用的二维实值离散傅里叶变换 (RDFT)。对于输入张量 $y \in \mathbb{R}^{H \times W}$ ，RDFT 产生一个复数值谱 $Y = \mathcal{F}(y) \in \mathbb{C}^{H \times W'}$ ，其中 $W' = \lfloor W/2 \rfloor + 1$ ，定义为：


$$\hat{Y}_{k,l} = \frac{1}{\sqrt{HW}} \sum_{m=0}^{H-1} \sum_{n=0}^{W-1} y_{m,n} e^{-2\pi i (\frac{km}{H} + \frac{ln}{W})} \quad (10)$$

其中 $k = 0, \dots, H - 1$ 且 $l = 0, \dots, W' - 1$ 。正交缩放因子 $1/\sqrt{HW}$ 确保帕塞瓦尔恒等式下的能量守恒。由于实值信号傅里叶变换的共轭对称性，只保留非冗余的半谱（当 W 为偶数时包括奈奎斯特频率），这在减少计算开销的同时保留了完全的可重构性。

FMVP模型（4）

— 频率门控约束（Frequency-Gated Constrain）

模型的这个部分同样在预测速度场 v_θ 与目标 (x_1-x_0) 之间的幅度差异。为了提高语义内容主要所在的低频区域的保真度，模型基于到直流 (频率 $(0,0)$) 分量（RDFT输出的左上角）的归一化距离构建了一个动态权重图：



FMVP模型（4）

— 频率门控约束（Frequency-Gated Constrain）

令 $h = H$ 和 $w_f = \lfloor W/2 \rfloor + 1$ 为 RDFT 后的空间高度和频域宽度。定义归一化坐标网格：

$$y_i = \frac{i}{h}, \quad i = 0, 1, \dots, h - 1$$

$$x_j = \frac{j}{w_f}, \quad j = 0, 1, \dots, w_f - 1 \quad (11)$$



到原点的归一化欧几里得距离为：

$$d_{ij} = \sqrt{y_i^2 + x_j^2}, \quad \forall i \in [0, h), j \in [0, w_f) \quad (12)$$

然后我们定义一个随距离指数衰减的门控函数：

$$w_{ij} = \exp(-\tau \cdot d_{ij}) + 0.1 \quad (13)$$

确保低频获得接近单位的权重，而高频被降低权重但未被完全消除，其中指数衰减率由 $\tau = 5$ 控制（+0.1 的底值防止梯度消失）。



FMVP模型（4）

— 频率门控约束（Frequency-Gated Constrain）

频率门控损失 (FGL) 为:

$$\mathcal{L}_{FGL}(\theta) = \mathbb{E}[\|W \odot |\mathcal{F}(v_{\theta}(x_t, t)) - \mathcal{F}(\mu_t(x_0, x_1))|\|_2^2] \quad (14)$$

其中 $|\cdot|$ 表示复数模 (magnitude) , W 是广播后的权重张量 (条目 w_{ij} 在 B, C, T 维度上复制)

总体训练损失为:

$$\mathcal{L}_{total}(\theta) = \lambda_{CFM} \mathcal{L}_{CFM}(\theta) + \lambda_{FGL} \mathcal{L}_{FGL}(\theta) \quad (15)$$

其中 $\lambda_{CFM} = 1$ 和 $\lambda_{FGL} = 0.2$ 平衡了像素空间流对齐和低频结构保真度, 以增强对抗扰动的鲁棒性

FMVP模型（5）

— 逐步求解ODE得到干净视频

我们已经得到了 v_θ ，运算即可得到 x_{purified}

$$x_{k+1} = x_k + v_\theta(x_k, t_k) \Delta t$$

回顾：

扩散模型的前向过程 - 可控掩盖率，增大噪声

+ 流匹配 - 核心网络

+ 复原时频率门控约束 - 根据频域定向语义，尝试在这个变量上指引模型

实验设置

1. 视频数据集

-**基准数据集**: 使用 UCF-101 和 HMDB-51 这两个标准的动作识别基准数据集。

-**数据划分**:

训练集: 将两个数据集的视频合并, 并随机抽取 60% 的片段用于训练预测速度场的 3D U-Net。

测试集: 从每个数据集互不重叠的保留部分 (held-out portion) 中, 各随机选择 500 个干净的视频片段进行评估。

2. 目标模型

实验选取了三种主流的视频识别模型作为攻击和防御的对象:

C3D 和 **I3D**: 作为主要的被攻击目标模型; **R3D**: 作为额外的跨模型验证对象, 用于评估 FMVP 防御效果是否依赖于特定的模型架构。所有模型均在各自的数据集上进行了预训练, 并具有竞争力的干净数据识别准确率。

3. 攻击方法

实验评估了三种不同类型的攻击策略:

PGD (Projected Gradient Descent): 一种基于梯度的攻击方法。

CW (Carlini & Wagner): 一种基于优化的攻击方法, 生成的扰动通常更隐蔽。

DiffHammer (DH): 一种自适应攻击 (Adaptive Attack), 用于探测生成式防御方法的“最坏情况”鲁棒性。

实验设置

4. 对比基线

为了验证 FMVP 的有效性，实验选取了多种先进的防御方法进行对比：

- 基于扩散模型的净化方法：DiffPure（包括 DDPM 和 DDIM 两种变体）。
- 视频特定的启发式防御：Defense Patterns (DP) 和 Temporal Shuffling (TS)。
- 基于流匹配的净化方法：FlowPure。

5. 评估指标

-准确率指标：

鲁棒准确率 (Robust Accuracy)：经过净化后，原本被错误分类的对抗样本能被正确恢复的比例。

干净准确率 (Clean Accuracy)：应用防御方法后，模型对干净样本的分类准确率。

-重建质量指标：使用 SSIM (结构相似性) 和 PSNR (峰值信噪比) 来衡量净化后视频与原始干净视频的相似度。

实验结果 — 总体结果

Method	UCF-101				HMDB-51				Avg. Robust
	Clean	Robust	SSIM	PSNR	Clean	Robust	SSIM	PSNR	
<i>PGD Attack (ℓ_∞, $\epsilon = 8/255$):</i>									
DiffPure-DDPM [Nie <i>et al.</i> , 2022]	84.0	70.0	0.8256	28.0512	89.0	75.0	0.8364	29.0245	72.5
DiffPure-DDIM [Nie <i>et al.</i> , 2022]	89.0	72.0	0.8155	28.5201	93.0	84.0	0.8531	30.2210	78.0
DP [Lee and Ro, 2023]	94.0	56.0	0.8758	28.8415	96.0	51.0	0.8514	29.6124	53.5
TS [Hwang <i>et al.</i> , 2024]	92.0	74.0	0.9437	25.6626	88.0	71.0	0.9271	24.3389	72.5
FlowPure [Collaert <i>et al.</i> , 2025]	94.0	77.0	0.8815	29.0451	96.0	81.0	0.8711	29.6333	79.0
FMVP ^{CW} (Ours)	96.0	72.0	0.8718	29.5671	<u>97.0</u>	85.0	0.8779	30.1256	78.5
FMVP ^{PGD} (Ours)	95.0	<u>84.0</u>	0.8896	<u>29.6415</u>	94.0	<u>91.0</u>	0.8812	29.5462	<u>87.5</u>
FMVP ^{Gaussian} (Ours)	<u>96.0</u>	78.0	0.8942	28.1649	94.0	89.0	0.8881	<u>30.2247</u>	83.5
<i>CW Attack (ℓ_2, $c = 0.001$):</i>									
DiffPure-DDPM [Nie <i>et al.</i> , 2022]	87.0	81.0	0.8275	27.6519	92.0	82.0	0.8365	26.9951	81.5
DiffPure-DDIM [Nie <i>et al.</i> , 2022]	89.0	75.0	0.8384	26.9642	<u>97.0</u>	83.0	0.8412	26.9593	79.0
DP [Lee and Ro, 2023]	93.0	44.0	0.8624	29.5208	<u>94.0</u>	49.0	0.8744	29.1258	46.5
TS [Hwang <i>et al.</i> , 2024]	90.0	79.0	0.9468	25.8049	91.0	70.0	0.9169	25.5281	74.5
FlowPure [Collaert <i>et al.</i> , 2025]	93.0	82.0	0.8919	27.5526	95.0	79.0	0.8625	28.9614	80.5
FMVP ^{CW} (Ours)	96.0	<u>89.0</u>	0.8952	27.9621	94.0	<u>90.0</u>	0.8697	29.6149	<u>89.5</u>
FMVP ^{PGD} (Ours)	<u>92.0</u>	79.0	0.8837	<u>31.6549</u>	92.0	83.0	0.8737	<u>30.8614</u>	81.0
FMVP ^{Gaussian} (Ours)	96.0	83.0	0.9019	30.4552	94.0	88.0	0.8803	29.6493	85.5
<i>DiffHammer (Adaptive, $\epsilon = 8/255$):</i>									
DiffPure-DDPM [Nie <i>et al.</i> , 2022]	85.0	8.0	0.8519	28.9061	89.0	9.0	0.8410	27.9633	8.5
DiffPure-DDIM [Nie <i>et al.</i> , 2022]	87.0	11.0	0.8614	28.5521	90.0	13.0	0.8526	26.9667	12.0
DP [Lee and Ro, 2023]	<u>96.0</u>	19.0	0.8692	28.1547	95.0	21.0	0.8699	29.4152	20.0
TS [Hwang <i>et al.</i> , 2024]	93.0	6.0	<u>0.9531</u>	26.4854	90.0	5.0	<u>0.9452</u>	25.8199	5.5
FlowPure [Collaert <i>et al.</i> , 2025]	95.0	12.0	<u>0.8912</u>	28.9106	<u>96.0</u>	16.0	<u>0.8891</u>	28.0215	14.0
FMVP ^{CW} (Ours)	95.0	16.0	0.8963	<u>28.9452</u>	94.0	19.0	0.8809	28.9134	17.5
FMVP ^{PGD} (Ours)	92.0	<u>20.0</u>	0.8852	28.5159	93.0	<u>24.0</u>	0.8799	<u>29.4937</u>	22.0
FMVP ^{Gaussian} (Ours)	94.0	<u>31.0</u>	0.8971	27.9523	92.0	<u>33.0</u>	0.8762	28.6634	<u>32.0</u>


Table 1: Comparison of purification performance and quality under PGD, CW, and adaptive DiffHammer attacks on C3D. We report Robust Accuracy (**Robust**, % ($\uparrow$)), Clean Accuracy after purification (**Clean**, % ($\uparrow$)), and video quality metrics (SSIM/PSNR) ($\uparrow$). **Avg. Robust** ($\uparrow$) denotes the average robust accuracy across both datasets. Underlined values indicate noteworthy results.

实验结果 — 不同部分的贡献（消融实验）


Method	Module		Acc. (%)			
	Mask	FGL	Clean	PGD	CW	DH
Base	—	—	94.5	79.0	80.5	14.0
+ Masking	✓	—	93.0	84.0	86.0	24.0
+ FGLoss	—	✓	95.5	80.0	81.0	16.0
+ LPIPS	✓	—	94.0	79.0	78.0	20.0
FMVP	✓	✓	<u>96.0</u>	<u>87.5</u>	<u>89.5</u>	<u>32.0</u>

Table 2: Ablation study of the FMVP framework. Results are averaged across UCF-101 and HMDB-51.

实验结果 — 掩码保留率和步数



实验结果 — 对抗样本检测（以0时归一化速度为指标）



实验结果 — 频域图




Figure 7: Power Spectral Density Analysis.

实验结果 — 用时

Method	Latency (s/video) ↓
DiffPure (DDPM)	35.91
DiffPure (DDIM)	3.62
FMVP (10 steps)	1.44
FMVP (12 steps)	1.72
FMVP (15 steps)	2.14
FMVP (20 steps)	2.88

Table 3: Inference time comparison on a single NVIDIA GeForce 4090 GPU.

结论 — 主要贡献

1. 提出了 FMVP 框架：该框架将条件流匹配（Conditional Flow Matching）与掩码策略（Masking）相结合，比较成功地破坏了一些对抗模式并恢复了净化后的视频；
2. 设计了频率门控损失（FGL）：基于频谱分析设计了一种新的损失函数——频率门控损失（FGL）。它在速度场预测中充当控制函数的角色，既能够有效地保留低频的语义信息，又抑制了高频的对抗噪声。
3. 验证了卓越的性能与检测能力：该模型在 UCF-101 和 HMDB-51 数据集上进行了广泛的实验。结果表明，FMVP 在面对标准攻击（PGD 和 CW）以及自适应攻击（DiffHammer）时，性能均优于当前最先进的方法（SOTA）。此外，该模型还能作为一个有效的对抗样本检测器使用。

结论 — 局限与后续研究方向

1. 推理成本与实时性挑战：仍依赖迭代式求解ODE，延迟较大；
2. 对高频噪声假设的依赖：如果攻击者专门设计针对低频分量的对抗攻击，这种方法就会失效；
3. 实验数据集规模限制：缺乏在更大规模、更多样化的数据集（如 Kinetics-400 或 Something-Something v2）上的验证。在这些背景更复杂、动作类别更多的数据集上，生成模型“恢复语义”的难度会呈指数级上升，FMVP 能否保持高效尚需验证。

欢迎大家批评指正！