



图像鉴伪论文分享

汇报人：彭思宇

2026/3/24



**Sida: Social media image deepfake
detection, localization and explanation
with large multimodal model**

Sida: 基于大型多模态模型的社交媒体图像深度伪造检测、定位与解释

2025 CVPR

为什么要关注社交媒体图像深伪？

- 生成模型快速发展，合成图越来越**逼真**。
- 社交媒体是假图传播的**重要场景**；假图可能误导公众、扭曲历史记录、削弱对数字内容的信任。
- 传统深伪研究多聚焦人脸，**不足以覆盖**真实社交媒体场景。

数据集局限

- 许多数据集主要关注人脸伪造；**非人脸**社交媒体图像深伪研究不足。
- 一些通用数据集基于 ImageNet，但**场景较简单**，不贴近社交媒体；使用较**旧生成技术**，伪造不够逼真。

任务定义局限

- 很多数据集只支持：真/假二分类 **或** 篡改区域定位。
- 很少**同时支持**：多类别检测 & 定位 & 文本解释。

贡献 1：提出 SID-Set

- 30 万张图像：100K 真实；100K 合成；100K 篡改。
- 支持多类别检测 & 定位 & 文本解释。

贡献 2：提出 SIDA

- 基于大视觉语言模型。
- 统一完成多类别检测 & 定位 & 文本解释。

贡献 3：实验验证

- 在 SID-Set 上达到很强性能。
- 在其他 benchmark 上也有较好泛化。

任务设定

论文任务设定：不是二分类，而是三任务统一

输入：


- 图像 x_i 。
- 文本提示 x_t 。

输出：

- 检测结果：真实 / 合成 / 篡改。
- 若为篡改，则输出 mask。
- 输出解释文本。

对比已有方法：

- 传统检测模型：只能判断真/假。
- 传统 IFDL 模型：只能定位篡改。



SIDA：同时做检测、定位、解释

SID-Set 相比已有数据集的优势

Dataset	Content	Data Source	Generator Year	Multiclass	Masks	Explanation
OHImg [39]	Overhead	Google Map	2023	✗	✗	✗
FakeSpotter [63]	Face	CelebA, FFHQ	2020	✗	✓	✗
ForgeryNet [24]	Face	CREMA-D	2021	✗	✓	✗
DCFace [27]	Face	FFHQ	2023	✗	✗	✗
DFE [58]	Face	IMDB-WIKI	2023	✗	✗	✗
RealFaces [48]	Face	Prompts	2023	✗	✗	✗
M3Dsynth [87]	Biology	DDPM, CycleGAN	2023	✗	✓	✗
CNNSpot [64]	Object	SDXL	2020	✓	✗	✗
CiFAKE [3]	Object	CIFAR	2023	✓	✗	✗
CASIA 2.0 [12]	General	Corel	2022	✗	✓	✗
ArtiFact [53]	General	COCO, FFHQ, LSUN	2023	✗	✗	✗
IMD2020 [45]	General	Places2	2020	✗	✓	✗
AIGCD [84]	General	LSUN, COCO, FFHQ	2023	✗	✗	✗
GenImage [86]	General	ImageNet	2023	✗	✗	✗
SID-Set	General	COCO, Flickr30k, MagicBrush	2024	✓	✓	✓

真实

- 来自 OpenImages V7。
- 共 100K。

合成

- 尝试多个开源生成模型：FLUX、Kandinsky 3.0、SDXL、AbsoluteReality 等。
- 由 5 位专家各审查 1000 张样本。
- 最终选择 FLUX。
- 用 Flickr30k 和 COCO 文本生成 100K 合成图像。

篡改

- 通过自动化篡改流程生成 100K 篡改图像。

局部篡改图像的生成流程

第一步：提取图像中的对象

- 利用 GPT-4o 从图像描述中抽取关键对象；尽量映射到 COCO 的标准类别。

第二步：生成目标区域掩码


- 使用 Language-SAM 为目标对象生成掩码；作为后续篡改和训练的真值标注。

第三步：建立篡改规则

- 物体替换：将原有物体替换成另一类物体；局部或属性修改：修改物体的局部部件或外观属性。

第四步：生成新的篡改图像

- 修改文字描述；利用扩散模型重新生成图像。



输入


- 图像
- 文字提示

核心设计

- 在原始多模态模型中加入两个特殊标记
 - <DET>: 用于检测
 - <SEG>: 用于分割

输出

- 一段文字解释
- 图像类别判断结果
- 被篡改区域的掩码



第一步：模型生成解释文本


$$\hat{y}_{des} = VLM(x_i, x_t)$$

第二步：提取检测标记的表示

- 从最后一层隐藏状态中取出 $\langle DET \rangle$
- 得到检测特征 h_{det}

第三步：送入检测头进行分类

$$\hat{D} = F_{det}(h_{det})$$



第一步：提取分割标记的表示

- 从最后一层隐藏状态中取出 <SEG>
- 得到分割特征 h_{seg}

第二步：利用检测信息增强分割信息

- 先将检测特征映射到与分割特征相同的维度
- 再通过注意力机制，让“全局判断信息”指导“局部定位信息”
- 通过残差连接保留原始分割信息

$$\tilde{h}_{det} = F(h_{det})$$

$$\tilde{h}_{seg} = MSA(\tilde{h}_{det}, h_{seg})$$

$$\tilde{h}_{seg} = \tilde{h}_{seg} + h_{seg}$$

第三步：结合图像视觉特征生成掩码

$$f = F_{enc}(x_i)$$

$$\hat{M} = F_{dec}(\tilde{h}_{seg}, f)$$

第一阶段：先训练检测与分割

$$L = \lambda_{det} L_{det} + \lambda_{mask} L_{mask}$$

$$L_{det} = L_{CE}(\hat{D}, D)$$

■ 其中：

$$L_{mask} = \lambda_{bce} L_{BCE}(\hat{M}, M) + \lambda_{dice} L_{DICE}(\hat{M}, M)$$

第二阶段：加入文本解释训练

$$L_{txt} = L_{CE}(\hat{y}_{des}, y_{des})$$

$$L_{total} = \lambda_{det} L_{det} + \lambda_{mask} L_{mask} + \lambda_{txt} L_{txt}$$

训练思路

- 先学会判断和定位
- 再学会生成解释文本

基础模型： LISA-7B-v1、 LISA-13B-v1

微调方式： LoRA

图像输入大小： 1024×1024

损失权重：

- 检测损失权重： 1.0
- 分割损失权重： 1.0
- 文本损失权重： 1.0
- 二值交叉熵权重： 2.0
- Dice 损失权重： 0.5

训练数据：

- SID-Set
- 过滤后的 MagicBrush

检测结果:

- SIDA-7B: 总体准确率 93.5, 总体 F1 值 93.5
- SIDA-13B: 总体准确率 93.6, 总体 F1 值 93.5

定位结果:

- SIDA-7B: AUC: 87.3; F1: 73.9; IoU: 43.8

鲁棒性:

- 在 JPEG 压缩、缩放、高斯噪声等干扰下性能仍较稳定

跨数据集泛化

- 在 DMImage 数据集上仍取得较好结果
- SIDA-7B: 总体准确率 91.8, 总体 F1 值 92.4

Methods	Year	Real		Fully synthetic		Tampered		Overall	
		Acc	F1	Acc	F1	Acc	F1	Acc	F1
AntifakePrompt [5]	2024	64.8(↑24.1)	78.6(↑10.5)	93.8(↑3.7)	96.8(↑1.1)	30.8(↑60.1)	47.2(↑33.2)	63.1(↑29.1)	69.3(↑23.4)
CnnSpott [17]	2021	79.8(↑9.2)	88.7(↑2.1)	39.5(↑51.2)	56.6(↑31.5)	6.9(↑61.2)	12.9(↑51.1)	42.1(↑39.3)	69.6(↑20.7)
FreDect [18]	2020	83.7(↓37.7)	91.1(↓43.5)	16.8(↑44.1)	28.8(↑37.2)	11.9(↑25.2)	21.3(↑31.7)	37.4(↑33.6)	23.4(↑47.2)
Fusing [26]	2022	85.1(↑4.1)	92.0 (↑0.7)	34.0(↑54.1)	50.7(↑38.4)	2.7(↑24.3)	5.3(↑26.1)	40.1(↑33.1)	29.1(↑40.3)
Gram-Net [37]	2020	70.1(↑19.1)	82.4(↑9.3)	93.5(↑4.4)	96.6(↑2.0)	0.8(↑89.1)	1.6(↑85.3)	55.0(↑37.1)	58.0(↑35.1)
UnivFD [46]	2023	68.0(↑0.3)	67.4(↑1.1)	62.1(↑24.3)	87.5(↑10.5)	64.0(↑28.5)	85.3(↑4.7)	64.0(↑21.7)	85.3(↑4.5)
LGrad [59]	2023	64.8(↓2.8)	78.6(↓2.5)	83.5(↓25.5)	91.0(↓23.7)	6.8 (↑92.3)	12.7 (↑86.1)	51.8(↑20.2)	55.5(↑23.9)
LNP [2]	2023	71.2(↓56.8)	83.2(↓60.2)	91.8(↓55.6)	95.7(↓60.1)	2.9(↑90.4)	5.7(↑88.9)	55.2(↓7.6)	58.2(↑4.1)
SIDA-7B	2024	89.1	91.0	98.7	98.6	91.2	91.0	93.5	93.5
SIDA-13B	2024	89.6	91.1	98.5	98.7	92.9	91.2	93.6	93.5

Methods	Years	Tampered		
		AUC	F1	IOU
MVSS-Net* [11]	2023	48.9	31.6	23.7
HIFI-Net* [21]	2023	64.0	45.9	21.1
PSCC-Net [36]	2022	82.1	71.3	35.7
LISA-7B-v1 [29]	2024	78.4	69.1	32.5
SIDA-7B	2024	87.3	73.9	43.8

	Detection		Localization		
	ACC	F1	AUC	F1	IOU
JPEG 70	89.4	90.1	86.2	71.8	42.3
JPEG 80	88.7	89.5	85.8	71.1	41.7
Resize 0.5	89.3	91.1	86.8	72.5	43.2
Resize 0.75	89.9	91.6	87.1	73.0	43.5
Gaussian 10	86.9	89.3	84.1	70.2	41.0
Gaussian 5	88.4	89.9	85.3	71.0	41.5
SIDA-7B	93.5	93.5	87.3	73.9	43.8

Methods	Real		Fake		Overall	
	Acc	F1	Acc	F1	Acc	F1
CNNSpot [17]	87.8	88.4	28.4	44.2	40.6	43.3
Gram-Net [37]	62.8	54.1	78.8	88.1	67.4	79.4
Fusing [26]	87.7	86.1	15.5	27.2	40.4	36.5
LNP [2]	63.1	67.4	56.9	72.5	58.2	68.3
UnivFD [46]	89.4	88.3	44.9	61.2	53.9	60.7
AntifakePrompt [5]	91.3	92.5	89.3	91.2	90.6	91.2
SIDA-7B	92.9	93.1	90.7	91.0	91.8	92.4

消融分析：

- 去掉注意力机制后，性能下降
- 用简单全连接替代注意力机制，性能也下降
- 说明“检测信息指导分割信息”的设计是有效的

论文的局限性：

- 数据集规模仍有进一步扩展空间
- 完全合成图像主要依赖 FLUX，可能带来分布偏差
- 篡改区域定位结果还有提升空间
- 文本解释不一定等于真正的因果解释



LEGION: Learning to Ground and Explain for Synthetic Image Detection
LEGION: 面向合成图像检测的定位与解释学习

2025 ICCV

为什么要研究合成图像检测？

- 图像生成技术快速发展，从 GAN 到扩散模型、再到自回归模型，生成质量不断提升
- 合成图像带来创作便利的同时，也带来虚假信息传播、隐私侵犯、版权争议等风险
- 检测技术是应对生成式图像风险的重要防线
- 但现有研究在数据集、定位能力和可解释性方面仍存在明显不足

现有工作的不足

1. 数据集方面

- 很多数据集使用较早的生成模型，图像质量较低
- 一些数据集偏动漫、卡通风格，与真实摄影图像差距较大
- 标注较粗糙，例如只给点标注，难以支持精细定位
- 一些数据集依赖清晰轮廓，不符合真实合成伪迹的复杂形态

现有工作的不足

2. 方法方面

- 传统方法依赖低层纹理线索，难以处理需要全局推理的伪迹
- 许多工作更关注“篡改图像”，对“完全合成图像”的研究不足
- 很少同时支持：检测 & 定位 & 文本解释

3. 应用方面

- 现有方法多把自己当作“防御者”
- 很少思考：检测结果能否反过来帮助图像生成模型提升质量

主要贡献

贡献一：提出 SynthScars 数据集

- 高质量、风格真实的完全合成图像数据集
- 共 12,236 张图像
- 提供像素级掩码、文字解释、伪迹类型标签

贡献二：提出 LEGION 框架


- 一个多模态大模型驱动的图片伪迹分析框架
- 同时完成检测、定位、解释

贡献三：实验表现优异

- 在多个基准上取得领先结果
- 具有较强鲁棒性和跨域泛化能力

贡献四：把检测模型变成“控制器”

- 用检测和解释结果指导图像再生成与局部修复
- 提升生成图像的自然度和真实性



任务设定与整体思路

作为防御者


- 判断图像是真还是假
- 找到伪迹区域
- 生成伪迹解释

作为控制器

- 用解释文本指导图像再生成
- 用伪迹掩码和解释指导局部修复

论文目标

- 不只是发现问题
- 还要帮助生成模型消除问题



数据规模

- 共 12,236 张完全合成图像
- 由人工专家进行标注

内容类型


- 人物、物体、场景、动物

伪迹类型

- 物理规律错误、形变扭曲、结构异常

标注形式

- 像素级区域掩码
- 详细文字解释
- 伪迹类别标签




SynthScars 相比已有数据集的优势

解决了以往数据集的四类问题

- 不再使用过时生成器产生的低质量图像
- 不再局限于动漫、卡通等非真实风格
- 不再使用粗粒度点标注
- 不再只依赖轮廓清晰的简单伪造区域

新数据集的特点

- 风格更接近真实照片
- 伪迹更复杂、更细微
- 边界更不规则、更贴近真实生成错误
- 更适合研究“完全合成图像”的伪迹分析



(c) Previous drawbacks

Dataset	Pixel-level Mask	Explanation	Artifact Type	Annotator	Valid Sample
CNNSpot [53]	✗	✗	✗	-	0
CIFAKE [2]	✗	✗	✗	-	0
UniFD [37]	✗	✗	✗	-	0
GenImage [72]	✗	✗	✗	-	0
Chamelon [59]	✗	✗	✗	-	0
AI-Face [28]	✗	✗	✗	-	0
PAL4VST [68]	✓	✗	✗	Human	10168
RichHF-18K [27]	✗	✗	✗	Human	11140
LOKI [62]	✗	✓	✗	Human	229
MMTD-Set [58]	✗	✓	✗	GPT-4	0
FF-VQA [17]	✗	✓	✗	GPT-4	0
SID-Set [16]	✗	✓	✗	GPT-4	0
SynthScars	✓	✓	✓	Human	12236

数据来源

- 从多个公开数据集中收集和筛选样本
- 包括 RichHF-18K、Chameleon、FFAA 等

预处理与质量控制

- 先使用预训练 ResNet-50 提取特征并聚类
- 再从各个簇中均匀采样，保证多样性
- 使用 Qwen2-VL-72B 过滤：
 - 低质量图像
 - 非真实摄影风格图像
 - 明显带有合成痕迹的异常样本

精细标注

- 采用不规则多边形掩码标注伪迹
- 对伪迹进行细粒度类别划分
- 提供详细文字解释

LEGION 的整体框架

四个核心组件


- 全局图像编码器
- 大语言模型
- 定位图像编码器
- 像素解码器

三项主要任务

- 深伪检测
- 伪迹定位
- 解释生成

一个扩展用途

- 图像再生成与局部修复的控制器



任务定义

- 将检测任务定义为二分类问题
- 输出：真实图像 / 虚假图像


具体做法

- 使用全局图像编码器提取图像特征
- 从特征中取出 CLS 标记
- 通过两层多层感知机输出分类结果

对应公式

$$I_x = E_g(x_i)$$

$$y_d = MLP(CLS(I_x))$$



(a) LEGION Framework

目标


- 让模型不仅输出判断结果
- 还能够解释图像中存在哪些伪迹

具体做法

- 使用基于 Vicuna 的大语言模型
- 将图像全局特征通过视觉到语言投影层映射到语言空间
- 与伪迹分析提示词拼接后输入大语言模型
- 输出自然语言解释

对应公式

$$y_e = L(x_p, P_{vl}(\vec{I}_x))$$



(a) LEGION Framework

核心思路


- 使用预训练的 SAM 编码器作为定位图像编码器
- 使用像素解码器生成伪迹掩码

具体过程

- 大语言模型在每段伪迹位置描述后附加一个特殊标记 <SEG>
- 取出与 <SEG> 对应的文本表示
- 通过“语言到提示”投影层映射到解码器特征空间
- 与图像编码器特征共同送入解码器
- 输出二值掩码

对应公式

$$M = D(E_l(x_i), P_{lp}(v_{seg}))$$



(a) LEGION Framework

两阶段独立训练

第一阶段

- 训练两个任务：
 - 伪迹定位
 - 解释生成
- 损失函数: $L_{s1} = \omega_{bce} L_{BCE}(M, \hat{M}) + \omega_{dice} L_{Dice}(M, \hat{M}) + \omega_{ce} L_{CE}(y_e, \hat{y}_e)$

第二阶段

- 训练任务：
 - 图像真假检测
- 损失函数: $L_{s2} = L_{CE}(y_d, \hat{y}_d)$

训练思路

- 先学会“找问题”和“说问题”
- 再学会“判真假”

从“防御者”到“控制器”

核心理念

- 检测技术和生成技术是相互促进的
- 如果模型能指出伪迹在哪里、为什么错
- 那这些信息就可以反过来指导生成模型进行修正

两条无训练优化路径


- 基于提示词修改的图像再生成
- 基于掩码和解释的局部修复

价值

- 不需要额外训练数据
- 可以逐步减少伪迹区域
- 提高图像自然度和真实感

基本流程

- 输入初始图像和初始提示词
- 使用文本到图像模型生成图像
- 用 LEGION 分析图像中的伪迹
- 将伪迹解释保存到记忆库
- 使用文本改写器修改提示词
- 再次生成图像
- 反复迭代，逐步优化结果




对应公式 $M_t = M_{t-1} + LEGION(I_t)$

$$P_{t+1} = Revise(P_t, M_t)$$

$$I_{t+1} = Regen(P_{t+1})$$

基本流程

- 输入一张图像
- 使用 LEGION 分析所有伪迹区域
- 将每个区域整理为三元组：
 - 位置
 - 掩码
 - 解释
- 将这些信息输入局部修复模型
- 按区域逐个修复
- 多轮迭代后得到更自然的图像



(c) Image Inpainting Pipeline

对应公式

$$A_t = \text{LEGION}(I_t) = \{(L_i, M_i, E_i)\}$$

$$I_{t+1} = I_t + \sum_{i=1}^k M_i \cdot (\text{Inpaint}(I_t, M_i, E_i) - I_t)$$

基本流程

- 采用 GLaMM 的预训练权重作为基础模型
- 第一阶段使用 LoRA 微调
- 训练设备：8 张 NVIDIA A100
- 第一阶段：
 - 学习率：1e-4
 - 每卡批大小：2
 - 损失权重：
 - 文本交叉熵：1.0、Dice 损失：0.2、二值交叉熵：0.4
- 第二阶段：
 - 仅训练检测分支的多层感知机
 - 学习率：1e-3
 - 每卡批大小：64
- 检测训练使用 ProGAN 数据

评估数据集

- SynthScars (同域测试)
- LOKI (跨域测试)
- RichHF-18K (跨域测试)

对比方法

- 传统专家模型：HiFi-Net、TruFor、PAL4VST
- 视觉语言模型：Ferret、Griffon、LISA
- 通用多模态大模型：InternVL2、Qwen2-VL 等

主要结果

- LEGION 在三个数据集上整体达到最优表现
- 在 SynthScars 上优于最强传统方法 PAL4VST
- 在跨域数据集上也表现出较好的泛化能力

Method	Source	SynthScars								LOKI		RichHF-18K	
		Object		Animal		Human		Scene		mIoU	F1	mIoU	F1
		mIoU	F1	mIoU	F1	mIoU	F1	mIoU	F1				
HiFi-Net [☆] [11]	CVPR23	43.74	0.45	45.28	0.03	46.21	0.84	45.90	0.04	39.60	2.41	44.96	0.39
TruFor [☆] [10]	CVPR23	46.99	14.82	48.45	17.57	49.02	15.43	48.93	12.64	46.55	<u>16.70</u>	48.41	<u>18.03</u>
PAL4VST ^{☆*} [68]	ICCV23	<u>50.46</u>	19.25	<u>52.55</u>	<u>21.61</u>	<u>59.18</u>	<u>35.70</u>	<u>52.55</u>	<u>19.14</u>	<u>47.34</u>	11.58	<u>49.88</u>	14.78
Ferret [□] [63]	ICLR24	30.10	20.81	27.17	15.78	25.54	13.87	30.64	13.79	24.50	18.88	26.52	16.22
Griffon [□] [65]	ECCV24	38.54	23.40	27.76	18.58	23.04	14.81	35.83	14.47	21.96	20.41	28.13	18.19
LISA-v1-7B ^{☆*} [22]	CVPR24	35.49	<u>23.70</u>	32.44	18.77	34.11	17.50	37.56	18.31	31.10	9.29	35.90	21.94
InternVL2-8B [□] [6]	CVPR24	41.08	13.36	41.22	7.83	41.21	3.91	41.68	7.55	42.03	10.06	39.90	9.58
Qwen2-VL-72B [□] [52]	-	33.89	23.25	32.46	21.98	26.92	14.75	39.00	18.17	26.62	20.99	27.58	19.02
LEGION[☆] (Ours)	-	54.62	29.90	54.52	27.43	60.82	39.44	53.67	24.51	48.66	16.71	50.07	17.41

解释生成结果

- 在 SynthScars 和 LOKI 上评估
- 指标：
 - ROUGE-L
 - 余弦相似度得分
- LEGION 在两个数据集上都优于其他开源和闭源多模态模型

检测结果

- 在 UniversalFakeDetect 基准上评估跨生成器泛化能力
- 在 GAN、CRN、IMLE 上取得最高准确率
- 在其他生成器上也保持有竞争力的表现


Method	Date	Params	SynthScars		LOKI	
			ROUGE-L↑	CSS↑	ROUGE-L↑	CSS↑
Qwen2-VL [52]	24.09	72B	25.84	58.15	11.80	37.64
LLaVA-v1.6 [30]	24.01	7B	<u>29.61</u>	<u>61.75</u>	<u>16.07</u>	<u>41.07</u>
InternVL2 [6]	24.07	8B	25.93	56.89	10.10	39.62
Deepseek-VL2 [57]	24.12	27B	25.50	47.77	6.70	28.76
GPT-4o [18]	24.12	-	22.43	53.55	9.61	38.98
LEGION (Ours)	25.03	8B	39.50	72.60	18.55	45.96

Method	GANs	Deepfakes	Perceptual Loss		Low Level Vision		Diffusion
			CRN	IMLE	SITD	SAN	
Co-occurrence [34]	75.17	59.14	73.06	<u>87.21</u>	68.98	60.42	85.53
Freq-spec [69]	<u>75.28</u>	45.18	53.61	50.98	47.46	57.12	69.00
CNNSpot [53]	85.29	53.47	<u>86.31</u>	86.26	66.67	48.69	58.63
Patchfor [4]	69.97	75.54	72.33	55.30	75.14	75.28	72.54
UniFD [37]	95.25	66.60	59.50	72.00	63.00	57.50	82.02
LDGard [45]	89.17	58.00	50.74	50.78	62.50	50.00	<u>89.79</u>
FreqNet [46]	94.23	97.40	71.92	67.35	88.92	59.04	83.34
NPR [47]	94.16	<u>76.89</u>	50.00	50.00	66.94	98.63	94.54
LEGION (Ours)	97.01	63.37	90.78	98.93	<u>79.44</u>	57.76	83.10


- 图像再生成后，人类偏好得分提升约 6.98%
- 局部修复后，人类偏好得分提升约 2.14%
- 说明 LEGION 的反馈确实可以帮助生成更自然的图像

HPS	Regeneration	Inpainting
Pre-refined Score (Avg.)	31.24	29.57
Post-refined Score (Avg.)	33.36	30.20
Growth Rate ↑	6.98%	2.14%

Case 1 (Easy): Style Distortion Adjustment



Case 2 (Hard): Detailed Structure Reshape



论文优点

- 数据集高质量、标注细
- 方法统一完成检测、定位、解释
- 提出了“检测模型作为控制器”的新视角

论文局限

- 主要聚焦完全合成图像，对其他类型伪造的覆盖有限
- 合成伪迹本身具有很强多样性，仍有提升空间
- 图像优化部分目前主要是定性和小规模定量验证

感谢批评指正

报告人：彭思宇

