



鉴伪量化论文分享

汇报人：彭思宇

2026/6/9



Unlocking the Potential of Lightweight Quantized Models for Deepfake Detection

挖掘轻量级量化模型在深度伪造检测中的
潜力

IJCAI 2025

- 现有 Deepfake 检测方法通常依赖 CNN、Transformer 或 CLIP 等大模型，以提升泛化性能。但这些模型计算量大、存储开销高，不适合实时或边缘部署。论文指出，Deepfake 检测本质上是二分类任务，因此模型中可能存在较大冗余，具有压缩和量化空间。




Figure 1: Comparison of deepfake detection models with different models, including the accuracy performance in four cases, the model storage and computational complexity.

论文的动机可以拆成三点：

- **大模型部署成本高**：如 CLIP-ViT-L 计算量可达 162 GFLOPs，存储 88.3MB。
- **小模型也有潜力**：ResNet-23、ResNet-34、ResNet-50 在 seen 数据上都能达到 99.9%，unseen 上差距并不大。
- **量化可进一步压缩模型**：低比特权重和激活可以显著减少计算与存储。


不同大小 ResNet 在 seen 数据上都是 99.9%，unseen 上 ResNet-23 为 77.6%，ResNet-34 为 80.0%，ResNet-50 为 79.4%，说明简单增大 backbone 对泛化提升有限。

	ResNet-23	ResNet-34	ResNet-50
Seen	99.9%	99.9%	99.9%
Unseen	77.6%	80.0%	79.4%

Table 1: Performance of different backbones on ForenSynths.

论文主要贡献可以总结为三项：

贡献	解释
首次系统探索 Deepfake 检测中的低比特量化	作者认为该方向此前研究较少，Deepfake 检测存在可压缩性
提出 NPR + CQB + SLR 的量化框架	分别解决输入表征、特征细节丢失、激活分布不均衡问题
在 GAN 和 Diffusion 跨源检测上取得较好效果	2/3-bit 模型在计算和存储大幅降低时保持较强泛化性能



- 输入图像
- NPR 表征
- 低比特量化 CNN / ResNet-23
- Connected Quantized Block, CQB
- Shifted Logarithmic Redistribution Quantizer, SLR
- 真假二分类

模块一——NPR 表征

NPR = Neighboring Pixel Relationships, 邻域像素关系。

作用：把 RGB 图像转成更适合 Deepfake 检测和量化的伪造痕迹表征。

论文认为 NPR 有两个优势：

- 保留边缘、纹理、像素关系等局部伪造痕迹；
- 去除部分语义信息，使模型更关注生成模型产生的上采样伪影。




Figure 3: Quantization error of each layer when the input data is original RGB images or NPR representations.




Figure 4: Visualizations for (a) RGB images and (b) NPR-processed representations of full-precision (*FP*) and MinMax *Quantized*.

CQB = Connected Quantized Block.

问题：低比特量化会造成细节损失，尤其是 Deepfake 检测依赖的纹理、边缘和局部伪影。

解决：在量化卷积主路径旁边加一个轻量的全精度辅助连接路径。

CQB 结构：

路径	作用
Quantized Main Path	低比特卷积，提取通用伪造特征
Full-precision Auxiliary Path	通过 pooling / sampling / repeat 保留细粒度纹理
Learnable α	自适应融合量化路径与辅助路径

论文指出，CQB 中卷积层仍然是量化的，但在 downsampling、upsampling 和 channel 不变的卷积旁边加入带权重的 shortcut connection， α 参数用于平衡低比特主路径和全精度辅助路径。

SLR = Shifted Logarithmic Redistribution Quantizer.

问题：激活值经过激活函数后，大量数值集中在 0 附近，分布非常不均衡。低比特量化时，如果仍然使用均匀量化，很多 bit 区间会浪费在少数值上，而多数 near-zero 激活被粗糙表示。

原始 post-activation 分布高度集中；经过 shifted logarithmic 变换后，分布被展开，更适合量化。作者提出先加 offset，再做 logarithmic redistribution，从而给 near-zero 区域更细的量化粒度。




Figure 7: Distributions of post-activation function, where (a) is the original activation, (b) is the logarithmic of shifted activation.

- 核心公式:

先平移: $X + \text{offset}$

再取对数: $\log(X + \text{offset})$

最后量化

- SLR 的优势:

展开 near-zero 激活;

缓解低比特量化的信息损失;

可以合并进 lookup table, 不引入额外计算开销。论文明确说明 SLR 可通过变换阈值集合并入查表策略, 因此没有额外计算开销。

■ 数据集与评估:

实验	数据集 / 设置	目的
Cross-GAN-Sources	ForenSynths	测试跨 GAN 生成源泛化
Cross-Diffusion-Sources	UniversalFakeDetect	测试跨 Diffusion 生成源泛化
指标	Acc / AP	分类准确率与平均精度
对比方法	CNNDetection、F3Net、 FrePGAN、LGrad、Ojha、 FreqNet、Lanzino 等	与全精度和低比特方法比较

论文把传统全精度方法和低比特量化方法分开比较，包括 MinMax、LSQ、N2UQ、1-bit BNN 以及作者自己的 2/3-bit 方法。

■ Cross-GAN 结果

■ 在 ForenSynths 的跨 GAN 测试中:

Methods	ProGAN		StyleGAN		StyleGAN2		BigGAN		CycleGAN		StarGAN		GauGAN		Deepfake		Avg.	
	Acc	AP	Acc	AP	Acc	AP	Acc	AP	Acc	AP	Acc	AP	Acc	AP	Acc	AP	Acc	AP
CNNDetection	91.4	99.4	63.8	91.4	76.4	97.5	52.9	73.3	72.7	88.6	63.8	90.8	63.9	92.2	51.7	62.3	67.1	86.9
Frank <i>et al.</i>	90.3	85.2	74.5	72.0	73.1	71.4	88.7	86.0	75.5	71.2	99.5	99.5	69.2	77.4	60.7	49.1	78.9	76.5
Durall <i>et al.</i>	81.1	74.4	54.4	52.6	66.8	62.0	60.1	56.3	69.0	64.0	98.1	98.1	61.9	57.4	50.2	50.0	67.7	64.4
Patchfor	97.8	100.0	82.6	93.1	83.6	98.5	64.7	69.5	74.5	87.2	100.0	100.0	57.2	55.4	85.0	93.2	80.7	87.1
F3Net	99.4	100.0	92.6	99.7	88.0	99.8	65.3	69.9	76.4	84.3	100.0	100.0	58.1	56.7	63.5	78.8	80.4	86.2
SelfBland	58.8	65.2	50.1	47.7	48.6	47.4	51.1	51.9	59.2	65.3	74.5	89.2	59.2	65.5	93.8	99.3	61.9	66.4
GANDetection	82.7	95.1	74.4	92.9	69.9	87.9	76.3	89.9	85.2	95.5	68.8	99.7	61.4	75.8	60.0	83.9	72.3	90.1
BiHPF	90.7	86.2	76.9	75.1	76.2	74.7	84.9	81.7	81.9	78.9	94.4	94.4	69.5	78.1	54.4	54.6	78.6	77.9
FrePGAN	99.0	99.9	80.7	89.6	84.1	98.6	69.2	71.1	71.1	74.4	99.9	100.0	60.3	71.7	70.9	91.9	79.4	87.2
LGrad	99.9	100.0	94.8	99.9	96.0	99.9	82.9	90.7	85.3	94.0	99.6	100.0	72.4	79.3	58.0	67.9	86.1	91.5
Ojha <i>et al.</i>	99.7	100.0	89.0	98.7	83.9	98.4	90.5	99.1	87.9	99.8	91.4	100.0	89.9	100.0	80.2	90.2	89.1	98.3
FrqeNet	99.6	100.0	90.2	99.7	88.0	99.5	90.5	96.0	95.8	99.6	85.7	99.8	93.4	98.6	88.9	94.4	91.5	98.5
Lanzino <i>et al.</i> (1-bit)	73.2	80.8	60.3	64.4	53.9	56.8	56.5	57.0	57.9	56.5	62.2	71.5	61.1	61.8	54.0	54.3	59.8	62.9
MinMax (4-bit)	91.0	97.5	74.4	84.4	73.7	88.7	48.9	49.0	50.9	51.0	78.3	97.8	47.4	45.7	54.8	54.2	64.9	71.1
LSQ (4-bit)	99.6	100.0	82.2	90.4	79.6	94.3	62.7	65.7	68.6	75.3	100.0	100.0	41.0	42.5	84.9	93.1	77.3	82.6
N2UQ (3-bit)	99.5	100.0	83.1	89.9	83.7	97.1	64.6	66.4	71.4	82.0	100.0	100.0	37.9	39.8	77.2	89.0	77.1	83.1
Ours (3-bit)	99.3	100.0	96.4	99.4	96.9	99.5	93.1	96.4	88.2	96.0	97.9	99.9	92.1	94.6	67.0	64.9	91.4	93.9
Ours (2-bit)	99.8	100.0	96.1	99.5	99.4	100.0	93.3	97.2	86.7	90.3	93.4	99.8	89.3	93.0	76.9	81.2	91.8	95.1

Table 2: Cross-GAN-Sources Evaluation on the ForenSynths. Separated by a horizontal line, the upper section presents the full-precision models and algorithms, while the lower section displays the low-bit quantized models with various quantization methods and bitwidth.

■ 重点: 作者的 2-bit 模型在平均 Acc 上达到 91.8%, 高于多数全精度方法, 并显著优于普通低比特量化方法。

■ Cross-Diffusion 结果

■ 在 UniversalFakeDetect 的跨 Diffusion 测试中:

Method	DALLE		Glide_100_10		Glide_100_27		Glide_50_27		ADM		LDM_100		LDM_200		LDM_200_cfg		Avg.	
	Acc	AP	Acc	AP	Acc	AP	Acc	AP	Acc	AP	Acc	AP	Acc	AP	Acc	AP	Acc	AP
CNNDetection	51.8	61.3	53.3	72.9	53.0	71.3	54.2	76.0	54.9	66.6	51.9	63.7	52.0	64.5	51.6	63.1	52.8	67.4
Frank	57.0	62.5	53.6	44.3	50.4	40.8	52.0	42.3	53.4	52.5	56.6	51.3	56.4	50.9	56.5	52.1	54.5	49.6
Durall	55.9	58.0	54.9	52.3	48.9	46.9	51.7	49.9	40.6	42.3	62.0	62.6	61.7	61.7	58.4	58.5	54.3	54.0
Patchfor	79.8	99.1	87.3	99.7	82.8	99.1	84.9	98.8	74.2	81.4	95.8	99.8	95.6	99.9	94.0	99.8	86.8	97.2
F3Net	71.6	79.9	88.3	95.4	87.0	94.5	88.5	95.4	69.2	70.8	74.1	84.0	73.4	83.3	80.7	89.1	79.1	86.5
SelfBland	52.4	51.6	58.8	63.2	59.4	64.1	64.2	68.3	58.3	63.4	53.0	54.0	52.6	51.9	51.9	52.6	56.3	58.7
GANDetection	67.2	83.0	51.2	52.6	51.1	51.9	51.7	53.5	49.6	49.0	54.7	65.8	54.9	65.9	53.8	58.9	54.3	60.1
LGrad	88.5	97.3	89.4	94.9	87.4	93.2	90.7	95.1	86.6	100.0	94.8	99.2	94.2	99.1	95.9	99.2	90.9	97.2
Ojha	89.5	96.8	90.1	97.0	90.7	97.2	91.1	97.4	75.7	85.1	90.5	97.0	90.2	97.1	77.3	88.6	86.9	94.5
FrqeNet	97.2	99.7	87.9	96.0	84.4	95.6	86.6	95.8	67.2	75.4	97.8	99.9	97.4	99.9	97.2	99.9	89.5	95.3
Lanzino <i>et al.</i> (1-bit)	55.2	57.9	59.7	62.5	59.9	63.2	61.6	65.0	57.2	59.3	60.8	63.5	61.5	65.4	57.1	59.6	59.1	62.0
MinMax (4-bit)	54.8	58.7	60.0	65.6	59.7	66.4	63.3	70.5	58.9	61.3	79.7	90.0	80.2	90.4	77.7	87.0	66.8	73.8
LSQ (4-bit)	66.0	94.0	91.9	99.5	88.2	99.1	90.3	99.3	72.1	79.4	95.2	99.8	96.0	99.8	94.0	99.7	86.7	96.3
N2UQ (3-bit)	71.9	84.5	87.8	95.6	83.7	92.8	85.5	93.8	68.5	76.7	91.0	97.3	90.8	97.0	90.3	97.1	83.7	91.8
Ours (3-bit)	82.7	96.0	96.4	99.3	94.3	98.9	93.5	98.8	86.0	94.6	97.9	99.5	97.5	99.4	97.8	99.5	93.3	98.2
Ours (2-bit)	82.5	94.0	96.5	99.3	96.2	99.5	95.6	99.4	82.5	94.0	95.7	99.3	94.7	99.2	95.1	99.3	92.4	98.4

Table 3: Cross-Diffusion-Sources Evaluation on the UniversalFakeDetect. Separated by a horizontal line, the upper section presents the full-precision models and algorithms, while the lower displays the low-bit quantized models with various quantization methods and bitwidth.

- **效率**: 论文总结其 2-bit ResNet-23 只需要 0.25 GFLOPs / 5.0 MB, 适合资源受限场景。

Method	Backbone	FLOPs (G)	Storage (MB)
Frank <i>et al.</i>	4-Layer CNN	0.0238	0.68
FreqNet	CNN	5.1	1.9
F3Net	Xception	8.4	22.9
CNNDetection	ResNet50	4.8	25.6
Ojha <i>et al.</i>	CLIP_ResNet50	12.2	25.6
Ojha <i>et al.</i>	CLIP_VIT-L/14	162	88.3
SelfBland	ResNet50+	8.34	44.6
LGrad	Discriminator+	75	46.6
GANDetection	EfficientNetB4×5	21	95
Lanzino <i>et al.</i>	BNext-T [1-bit]	0.89	13.3
Lanzino <i>et al.</i>	BNext-M [1-bit]	3.4	46.5
FP Basline	ResNet-23	2.7	62
LSQ	ResNet-23 [4-bit]	0.37	7.9
N2UQ	ResNet-23 [3-bit]	0.30	6.9
Ours	ResNet-23 [3-bit]	0.32	6.9
Ours	ResNet-23 [2-bit]	0.25	5.0

Table 4: Efficiency of methods, backbones and quantized bitwidth. For low-bit quantized methods, we calculate OPs as theoretical computation complexity, while for full-precision models, we use FLOPs.

- **消融实验：**这说明三个模块都有效，其中 NPR 和 CQB 的贡献更大，SLR 是进一步优化低比特激活量化。




Figure 9: Ablation study on Cross-GAN-Sources Evaluations.

优点:

- 问题重要: Deepfake 检测需要实时化、端侧化。
- 切入点新: 不是继续堆大模型, 而是研究 Deepfake 检测的低比特量化。
- 方法有针对性: NPR 解决输入量化友好性, CQB 解决纹理细节丢失, SLR 解决激活分布不均。
- 实验效果强: 2/3-bit 模型在 GAN 和 Diffusion 跨源检测上表现不错, 同时显著降低计算和存储。

局限:

- 严格来说更偏 “图像级 Deepfake / AI-generated image detection”: 虽然应用背景提到视频平台和 Deepfake, 但实验主要是在生成图像检测数据集上做跨源评估, 并没有重点建模视频时序信息。
- 真实部署效果仍需验证: 论文报告理论计算量和存储, 但端侧硬件上的真实延迟、能耗、吞吐不一定等价。
- 低比特模型依赖特定输入表征 NPR: 如果伪造类型不是上采样伪影主导, NPR 的泛化可能需要进一步验证。
- 对真实社交平台压缩、重编码、截图等干扰的鲁棒性还可以继续研究。



Faster Than Lies: Real-time Deepfake Detection using Binary Neural Networks

比谎言更快：利用二元神经网络实现实时深度伪造检测

CVPR Workshop 2024

背景问题

Deepfake 和 AI 生成图像越来越逼真，现有检测方法通常依赖较大的 CNN 或 Transformer 模型。这些模型虽然准确率高，但存在几个问题：


- 计算量大；
- 参数多；
- 推理速度慢；
- 不适合移动端、个人电脑、边缘设备等低资源场景。

切入点

- 作者选择 Binary Neural Networks, BNNs，因为 BNN 将权重和激活都量化到 1-bit，可以把大量浮点运算替换成位运算，从而减少计算和存储开销。论文指出，BNN 很适合移动端、个人电脑等资源受限设备上的实时检测。

论文主要贡献可以总结为四项：

贡献	解释
首次将 BNN 系统用于 Deepfake 检测	作者声称这是 first-ever implementation of a BNN for deepfake detection
引入 FFT 和 LBP 辅助通道	引入 FFT 和 LBP 辅助通道
在三个数据集上验证	在三个数据集上验证
实现较高效率	在多个实验中显著减少 FLOPs，最高提到约 20× 推理 FLOPs 降低



- 输入 RGB 图像后，额外计算 FFT magnitude 和 LBP 两个通道，拼接成 5 通道输入；经过 Adapter 压回 3 通道，再送入 BNext backbone，最后通过 classifier 输出真假分类。

- RGB 图像
- 提取 FFT magnitude
- 提取 LBP texture map
- RGB + FFT + LBP 拼接成 5 通道输入
- Adapter: 5 通道 $\rightarrow$ 3 通道
- BNext 二值化 Backbone
- 全精度分类器
- Real / Fake

关键模块 1: FFT 频域特征

为什么用 FFT?

生成图像往往会在频域留下异常模式，比如某些高频或周期性伪影。RGB 空间中这些差异可能不明显，但频域分析可以把它们放大。

论文中使用 FFT magnitude channel 来突出频域异常。作者认为，Deepfake 可能在频域中引入真实图像不存在的失真，因此 FFT magnitude 可以帮助模型发现这些异常。

关键模块 2: LBP 纹理特征

什么是 LBP?

LBP, Local Binary Pattern, 是一种传统纹理描述子。它通过比较每个像素和邻域像素的大小关系, 编码局部纹理模式。

为什么用于 Deepfake 检测?

Deepfake 图像在人脸区域、边缘区域或局部纹理上可能存在微小异常。LBP 可以增强这些局部纹理差异。

论文中说, LBP 被用于捕捉 facial features 的独特纹理, 因为 Deepfake 通常难以完全准确地保持这些局部纹理。

关键模块 3: Adapter

因为原始图像是 3 通道 RGB, 加上 FFT 和 LBP 后变成 5 通道:

- RGB: 3 channels
- FFT magnitude: 1 channel
- LBP: 1 channel
- Total: 5 channels

但作者使用的 BNext backbone 需要输入 3 通道图像, 因此他们在 backbone 前加了一个 **Adapter**。

Adapter 本质上是一个卷积层, 用来把 5 通道输入压缩回 3 通道输入, 保持与预训练 backbone 的输入格式一致。

关键模块 4: Binary Backbone

论文使用的主干是 BNext。

BNN 的基本思想是：把全精度卷积中的权重和激活都二值化到 $\{-1, +1\}$ 。普通卷积是：

$$Y = A_r \otimes W_r$$

二值卷积近似为：

$$Y \approx (A_b \circledast W_b) \odot \alpha$$

其中：

- A_b 是二值激活；
- W_b 是二值权重；
- $\circledast$ 表示位运算，包括 XNOR 和 POPCOUNT；
- α 是缩放因子，用于缓解二值化误差。

论文说明，BNext 中卷积操作是 binary 的，其他操作量化到 INT-4，从而在运算效率上更高；同时 BNext 仍保留 full-precision skip connection 和 INT-4 分支，以缓解信息传播瓶颈。

■ 论文使用三个数据集：

数据集	数据集	数据集
COCOFake	基于 COCO, 用 Stable Diffusion 生成假图像	超过 650K 训练图像, 30K 验证, 30K 测试
DFFD	Diverse Fake Face Dataset, 面部操纵检测	包含 identity swap、expression swap、attribute manipulation、synthetic faces
CIFAKE	类似 CIFAR-10 的真假图像数据集	60K 真图 + 60K Stable Diffusion 假图

论文评价指标包括：Accuracy; AUC; FLOPs。

训练细节方面，作者使用 AdamW、binary cross-entropy loss, batch size 为 128, 并在 RTX 2080Ti GPU 上实现。

■ COCOFake 结果

Method	Model	Pre-training dataset	Accuracy	AUC	Parameters (M)	FLOPs (G)
[2]	ResNet50	ImageNet	90.31	-	25.6	4.8
	ViT-B/32	ImageNet	87.64	-	88.3	8.56
	CLIP-ResNet50	OpenAI WIT	99.07	-	25.6	4.8
	CLIP-ViT-B/32	OpenAI WIT	99.11	-	88.3	8.56
	OpenCLIP-ViT-B/32	LAION-400M	97.88	-	88.3	8.56
	OpenCLIP-ViT-B/32	LAION-2B	99.68	-	88.3	8.56
Ours	BNext-T with frozen backbone	ImageNet	83.65	81.98	29.8	0.89
	BNext-S with frozen backbone	ImageNet	93.15	95.19	67.1	<u>1.91</u>
	BNext-M with frozen backbone	ImageNet	84.59	82.11	133	3.39
	BNext-T	ImageNet	99.25	99.86	29.8	0.89
	BNext-S	ImageNet	<u>99.28</u>	<u>99.89</u>	67.1	<u>1.91</u>
	BNext-M	ImageNet	99.18	99.91	133	3.39

Table 1. Results on the COCOFake validation set. The models from [2] were trained on different datasets, including ImageNet [26], OpenAI WIT [49], LAION-400M [46] and LAION-2B [47]. **Bold** and underlined values respectively indicate the first and second-best results within their column.

重点:

- BNext-T 只有 0.89G FLOPs, 但 Accuracy 达到 99.25%;
- 相比 ResNet50 的 4.8G FLOPs, BNext-T 计算量低很多;
- 与 OpenCLIP-ViT-B/32 相比, 准确率略低, 但计算量远小。

论文认为, 这说明低比特 BNN 在 Deepfake 检测中可以在保持精度的同时大幅降低计算量。

■ DFFD 结果

Method	Model	Accuracy	AUC	Parameters (M)	FLOPs (G)
[10]	Xception	-	99.64	40.0	18.0
	VGG16	-	99.67	138.4	15.5
Ours	BNext-T with frozen backbone	89.56	87.65	29.8	0.89
	BNext-S with frozen backbone	89.69	88.58	67.1	<u>1.91</u>
	BNext-M with frozen backbone	89.61	86.64	133	3.39
	BNext-T	<u>98.95</u>	99.94	29.8	0.89
	BNext-S	99.01	99.94	67.1	<u>1.91</u>
	BNext-M	98.75	<u>99.92</u>	133	3.39

Table 2. Results on the DFFD test set. **Bold** and underlined values respectively indicate the first and second-best results within their column.

在 DFFD 上, BNext 系列模型的 AUC 达到 99.9 左右, 同时 FLOPs 远低于 Xception 和 VGG16。

■ CIFAKE 结果

Method	Model	Accuracy	AUC	Parameters (M)	FLOPs (G)
[53]	ResNet-50	95.00	99.00	25.6	4.8
	VGG	96.00	99.00	133	7.63
	DenseNet	98.00	99.00	7.9	5.6
Ours	BNext-T with frozen backbone	83.89	91.70	29.8	0.89
	BNext-S with frozen backbone	80.71	89.25	67.1	<u>1.91</u>
	BNext-M with frozen backbone	82.77	90.73	133	3.39
	BNext-T	97.29	99.65	29.8	0.89
	BNext-S	96.96	99.55	67.1	<u>1.91</u>
	BNext-M	<u>97.35</u>	<u>99.62</u>	133	3.39

Table 3. Results on the CIFAKE test set. All the models were pre-trained on the ImageNet [26] dataset. **Bold** and underlined values respectively indicate the first and second-best results within their column.

在 CIFAKE 上, BNext 的准确率略低于 DenseNet, 但 FLOPs 明显更低, 说明它在精度和效率之间取得了较好的折中。

- 论文对不同输入特征组合做了消融实验，数据集是 COCOFake。

Ablation	Variations	Accuracy (%)
Baseline	-	<u>90.35</u>
Features added to the learned ones	Magnitude	82.36
	FFT	88.18
	LBP	88.42
	Magnitude and FFT	81.20
	Magnitude and LBP	81.67
	FFT and LBP	91.60
	Magnitude, FFT and LBP	81.56

结论：

- 单独加 FFT 或 LBP 效果不如 baseline；
- FFT + LBP 组合最好，达到 91.60%；
- Sobel / Magnitude 类边缘信息帮助有限，甚至会降低性能；
- FFT 和 LBP 互补：FFT 关注频域异常，LBP 关注局部纹理异常。

优点:

- **方向明确**: 面向实时检测。这篇论文不是追求 SOTA 大模型, 而是关注真实部署场景, 尤其是移动端、个人电脑、低资源设备。
- **方法简单有效**: 整体框架并不复杂: RGB + FFT + LBP + BNext; 但是能够明显降低 FLOPs, 并保持较高准确率。
- **把传统特征和深度模型结合**: FFT 和 LBP 都是比较传统的图像分析方法, 作者把它们作为额外通道输入 BNN, 使模型在低比特条件下仍能获得频域和纹理线索。
- **实验覆盖多个数据集**: COCOFake、DFFD、CIFAKE 分别覆盖通用图像、面部伪造、小尺寸合成图像, 说明方法有一定泛化能力。

局限:

- **更偏图像检测，不是真正的视频时序检测：**虽然标题和背景中使用了 Deepfake Detection，但实验主要是图像级真假分类，没有建模视频中的时间一致性、帧间伪影、运动异常等信息。
- **理论 FLOPs 不等于真实加速：**论文结论中也承认，BNN 的真实部署需要专门的框架或硬件加速器，否则理论上的低比特优势不一定能完全转化为实际速度提升。
- **依赖 ImageNet 预训练：**作者指出，他们只使用 ImageNet 预训练，而其他方法可能使用更大规模预训练数据，因此不同方法之间的预训练条件并不完全一致。
- **对真实压缩视频鲁棒性不足：**论文相关工作部分提到，Deepfake 检测模型在面对真实世界失真，例如视频压缩时，性能可能下降。但本文实验中并没有系统评估视频压缩、重编码、社交平台传播等干扰。

感谢批评指正

报告人：彭思宇

